LRLS-v1.1：硬约束下双体探索–开发强化学习规范与参考仿真

桑杰逊（**Jason Sang**）

独立研究者

预印本 v1.0 · 2026 年 11 月 5 日

摘要

本文提出 LRLS（Lobster RL Specification，龙虾双体强化学习规范）：把强化学习中经典的「探索–开发」权衡按角色拆分为两类异构智能体种群与一个调度器。高熵的小龙虾种群负责全局粗采样，产出候选「淤泥窟」；低熵、约束感知的波士顿龙虾种群通过局部求精与约束投影，把候选升级为经过核验的可行解「岩礁隙」；调度器负责分配种群预算、派发任务与触发全域重采样。规范固定了状态四分、六个动作原语、统一奖励结构 $r = r_{obj} - \lambda_v C_v + \lambda_e H - \lambda_m C_m$、共享记忆池 schema、四阶段训练流程、七项必报指标与安全兜底层。v1.1 *RoboZero* 进一步把智能体映射到异构机器人集群，引入几何嵌入空间、gossip 记忆同步、多机共识投票与零样本迁移路径。为使规范可执行、可检验，本文同时发布零依赖的确定性参考仿真（单 HTML 文件，1100 tick，22×22 收益地形，12 个智能体），并给出四档难度的单次运行结果。本文是一份规范与参考实现，不宣称算法性能更优：没有学习式调度策略、没有多种子统计、没有基线对比、没有真实机器人实验，第 6 节逐条列明。本文的价值在于把「学习式切换调度器是否优于固定温度 / 熵退火」这一核心假设，变成一个精确、可复现、可被证伪的目标。

关键词：强化学习规范；探索–开发；多智能体系统；带约束寻优；异构机器人集群；零样本迁移；小龙虾优化算法

1 引言

探索–开发的平衡是强化学习最基础的问题之一（Kaelbling 等，1996）。主流工程做法是保持单一策略，用一个调度量调节探索压力：熵系数（Haarnoja 等，2018）、温度参数、ε 衰减或手工退火曲线。调度本身几乎从不被学习，它只是一个超参数。

仿生优化器也做同样选择。小龙虾优化算法（**Crayfish Optimization Algorithm, COA**）由 Jia 等（2023）发表于 *Artificial Intelligence Review*，模拟「避暑（探索）/ 竞争 / 觅食（开发）」三阶段，并用温度阈值在阶段间切换。COA 是真实、可引用的小龙虾启发式元启发式算法，本身已经完成了一次固定的探索–开发权衡。这里特别说明：本工作早期草稿曾引用所谓「龙虾优化算法」，并描述「巡游、领地争夺、躲避天敌、迁徙」等算子——这些并不属于 COA，且草稿中存在占位符参考文献。本文已删除相关论断并改为正确引用。

LRLS 只问一个窄问题：如果切换机制不是阈值，而是一个智能体，会怎样？ 不是「一个种群 + 一个温度旋钮」，而是两个在观测与行为上真正异构的种群，加一个从全局状态决定「何时把资源从发现切到核验」的控制器。结构上接近分层强化学习 / options（Sutton 等，1999）与专家混合的门控，但分工被绑定到显式的记忆 schema、固定的动作原语词表与硬约束安全层，因此得到的是可实现的规范，而不是一张架构图。

关于隐喻。 两个角色名来自对《荀子·劝学》「蟹六跪而二螯……用心躁也」的重读：原文是批评浮躁不专，本文把它拆成两种互补气质——「用心嬉也」（好动广搜）与「用心惕也」（警觉守静）。这是叙事性重解释与语义翻转，不是生物学先验，特此声明，以免读者把文学装置误当作经验证据。配套的《龙虾之禅 · The Zen of OpenClaw》（桑杰逊，2026）是同一世界观下的 41 条「心法」文本，不含技术主张。

本文贡献：（1）完整可实现的规范（第 3 节）；（2）确定性、零依赖、单 solver 驱动所有视图的参考实现（第 4 节）与四档难度的说明性结果（第 5 节）；（3）明确界定「尚未证明什么」（第 6 节），包括核心假设为何仍未被验证。

---

2 相关工作

小龙虾与群智能优化。 COA（Jia 等，2023）以温度门控探索 / 竞争 / 觅食三阶段，围绕食物中心更新位置。LRLS 不与 COA 竞争优化器性能，而是把「小龙虾角色」作为 RL 分解的一半，用可调度控制器替换固定温度门。与 COA 自身温度调度做公平对比，是后续必须补的基线。

分层 **RL** 与 **options**。 时序抽象（Sutton 等，1999）把动作选择分层。LRLS 的六个原语本质上是一个固定的 option 集，调度器是 option 选择策略；与经典 options 不同，option 清单存放在共享的结构化记忆池里并带可行性标签。

最大熵与熵正则 **RL**。 SAC（Haarnoja 等，2018）对单策略加熵项。LRLS 只对探索分支施加熵正则（3.8 节明确禁止对波龙分支使用），是结构性分离而非标量调节。

多智能体 **RL** 与 **CTDE**。 MADDPG（Lowe 等，2017）与 MAPPO（Yu 等，2022）确立集中训练、分散执行。LRLS-v1.1 的集群扩展采用 CTDE，并叠加 gossip 记忆一致性与共识投票，更接近分布式一致性问题，而非标准 MARL 的信用分配。

零样本迁移与域随机化。 域随机化（Tobin 等，2017）与零样本泛化综述（Kirk 等，2023）界定了 v1.1 的说法：冻结策略部署到未见目标域，属于零样本迁移 / 域泛化，不是 LLM 语境的零样本学习；仍依赖预训练编码器，只是不需要目标域交互轨迹。

---

3 LRLS 规范

3.1 角色与术语

术语	符号	释义
栖息地	H	候选区域，分淤泥窟 H_m、岩礁隙 H_r
小龙虾智能体	A_C	探索器：粗感知、大步长、高熵
波龙智能体	A_B	警戒矿工：细感知、小步长、约束敏感
调度器	A_S	决定种群规模、切换时机、任务指派
全局记忆池	M	轨迹库、栖息地索引、风险图、适应度记录
警戒代价	C_v	约束违反、碰撞、越界的即时代价
嬉熵	H	探索分布熵

A_C 不输出最终可行解，只输出候选区域索引；A_B 消费淤泥窟、提交核验后的岩礁隙；A_S 的学习才是真正的研究假设所在。

3.2 状态空间

$$s = [s_{pos}, s_{reward}, s_{risk}, s_{memory}]$$

s_{pos}：坐标、邻域采样点、梯度估计；s_{reward}：当前目标值、邻域最优、历史增量；s_{risk}：约束残差、边界距离、局部冲突密度；s_{memory}：淤泥窟数、优质岩礁隙数、衰减标记。分支规则：A_C 接收降维粗编码，A_B 接收完整精细风险与约束特征。这一不对称是「异构」的实质，而非命名差异。

3.3 动作原语

$$A = \{Wander, MarkCave, DigLocal, VigilScan, Migrate, Abandon\}$$

依次对应：大步全局采样、登记淤泥窟、邻域局部优化、评估约束并投影位置、离开并请求重派、标记衰减降级。连续版本附带步长、扰动幅度、局部迭代轮数。

3.4 奖励

$$r(s,a) = r_{obj} - \lambda_v C_v + \lambda_e H - \lambda_m C_m$$

A_C 提高 λ_e、降低 λ_v（容忍轻微无效采样）；A_B 提高 λ_v、降低 λ_e（优先可行）；A_S 以全种群最优可行解的提升为回报，而非自身局部收益。C_m 为迁移开销，抑制在栖息地间反复横跳。

3.5 记忆池

统一记录 schema：

```
{
  "hid": "uuid",
  "type": "mud_cave | reef_gap",
  "pos": [0.0, 0.0],
  "score": 0.0,
  "feasible": false,
  "risk": 0.0,
  "created_by": "C | B",
  "last_visit": 0,
  "decay": 0.0,
  "traj_refs": ["trj_id_1"]
}
```

淤泥窟按 FIFO + 收益优先级淘汰；岩礁隙长期保留、持续衰减，风险激增时降级；轨迹绑定栖息地 ID 以支持离线回放。三个回放分区：嬉池（探索多样性）、惕池（带约束标签的求精轨迹）、调度池（全局状态–动作对）。

3.6 调度器

A_S 观测全局栖息地分布、各区收益速率、风险水平与种群预算；动作包括设定 (N_C, N_B)、把淤泥窟指派给波龙、升降全局探索系数、在收益停滞时触发全域重采样。规范允许学习式策略、规则热启动或两者混合；第 **4** 节的参考仿真只实现了规则热启动。

3.7 训练流程（强制顺序）

1. 行为克隆预热：用启发式专家轨迹预训练 A_C, A_B, A_S，避免上线初期随机乱探索。
2. 协同在线 **RL**：三分支同步收集轨迹、分别更新。
3. 离线提纯：取优质岩礁隙轨迹做约束强化与价值蒸馏。
4. 校准：在验证集扫描 $\lambda_v, \lambda_e, \lambda_m$。

更新约束：波龙不得在未标记淤泥窟上无限制漫游；同一淤泥窟连续三次指派仍不可行则永久降权；禁止对 A_B 施加高熵鼓励；多智能体版本采用 CTDE。

3.8 安全兜底

（i）投影层：A_B 的每个动作必须投影到可行集，失败则标记高风险；（ii）熔断：全局可行率低于阈值时，A_S 提高小龙虾占比并重启全域采样；（iii）隔离：高风险区不指派给波龙；（iv）版本锁：更换目标函数必须重置记忆池，防止旧轨迹污染。

3.9 必报指标

最优可行解 · 发现率 · 可行率 · 探索熵 · 迁移开销 · 收敛步数 · 扰动下的鲁棒性衰减。每条 rollout 日志需含 step、agent_type、habitat_id、action、raw_reward、risk、feasible、entropy，以及环境版本与规范版本。

3.10 v1.1 ***RoboZero*** 扩展

新增：跨本体的几何嵌入空间 Z；gossip 同步的本地记忆副本；洞穴升级前的多机共识投票；求精机器人掉线时的故障接管；三条零样本路线（行为原型、语义提示、启发式兜底）。零样本推理阶段奖励只用于

评估、不用于梯度更新，策略冻结。诚实的范围界定：这是零样本迁移（不需要目标域交互轨迹），不是零样本学习（不处理训练中未见的语义类别），预训练编码器仍然必需。

---

4 参考实现

为使规范可检验，本文发布单文件离线 **HTML**（无 CDN、无构建步骤、零依赖）。实现遵循「可拆解模拟器」范式：一个确定性 solver 预计算完整时间轴，所有视图（3D 地形、部件剖开、指标面板、曲线、俯视图、任务板、事件日志）都通过纯函数 `render(t)` 读取同一帧。

参数	取值	含义
Ticks	1100	预计算完整时间轴
地形	22 × 22	带硬约束区的合成目标曲面
智能体	22	混合 A_C / A_B 种群
`TAU_MUD`	0.38	登记淤泥窟的收益阈值
`VOTE_NEED`	2	升级岩礁隙所需共识票数
`B_MAX` / `C_MAX`	4 / 8	调度器种群上下界
`LAMBDA_V` / `LAMBDA_M`	1.0 / 0.15	违例与迁移权重

任务流水线为 `MAP → DISCOVER → VERIFY → REFINE → REPORT`。三处实现细节决定了「能否真的解出问题」：（i）`DigLocal` 在接纳候选前做风险梯度排斥；（ii）`VigilScan` 施加有界约束投影（最多三步梯度）并允许复检投票，避免共识永久卡死；（iii）探索器不做事前风险预筛——早期版本正是在发现阶段过度过滤，导致 `best = 0.000` 且 `REPORT` 永不闭环。全局收益停滞会触发全域重采样。

可复现性：带种子的确定性 PRNG、URL 状态参数（`?t=680&part=S&view=top&pause=1`）、键盘单步、可回看任意 tick 的时间轴。给定参数组总是产生完全相同的时间轴。

---

5 说明性结果

四组参数经同一确定性 solver 运行。以下是单次运行的求解器行为示意，不是统计评估；不涉及学习式策略，也未与任何基线比较。

档位	最优可行解	岩礁隙	弃窟	约束违例	首解 **tick**	**REPORT**
轻松（λ_e .35，风险 .25，复杂度 .20）	0.998	16	0	0	63	已闭环
默认（λ_e .35，风险 .55，复杂度 .50）	1.000	16	0	5	63	已闭环
高风险（λ_e .35，风险 .85，复杂度 .70）	1.000	11	5	22	63	已闭环
极限（λ_e .70，风险 .95，复杂度 .95，施压 .95）	1.000	15	1	50	79	已闭环

在此证据强度下只能得出两点：（a）四档均能闭环，说明规范内部是可执行的；（b）约束越难，违例与弃窟越多、首解越晚，说明难度滑块不是装饰。本文不主张相比 **COA**、固定温度 / 熵退火、**PPO**、**MAPPO** 或任何基线有提升。 另外，目标曲面是合成的且已归一化，「1.000」表示「找到了求解器自身已知的最优」，不是基准测试分数。

---

6 局限

1. 核心假设未被验证。 参考实现中的调度器是规则热启动；「学习式调度器优于固定温度 / 熵退火」恰恰是本规范要支撑、而本文没有回答的问题。
2. 无统计证据。 每档仅一次确定性运行；无多种子、无均值±标准差、无显著性检验、无置信区间。
3. 无基线。 未与 COA、固定调度的 SAC/PPO、随机搜索、MAPPO 比较。
4. 无真实具身。 v1.1 集群仍是设计；地形是合成 2D 函数，不是物理仿真或机器人硬件；gossip 延迟、丢包、执行器噪声均未模拟。
5. 隐喻不是证据。 荀子重读是刻意的语义翻转，仅作命名与叙事装置，不提供行为先验，不应被引用为生物学依据。
6. 「零样本」取迁移义。 仍需要预训练编码器，属于域泛化，不是面向未见任务语义的零样本学习。
7. 兜底混淆。 v1.1 允许低置信度时回退到原生启发式；未来评估必须把兜底作为独立消融变量，否则无法判断提升来自表征、调度还是规则。
8. 引用卫生。 早期草稿含占位符参考文献，并误称「CoRL 是 CCF-B」。本文已删除；CCF 只是分级目录而非投稿渠道，且 CCF 目录中并无 CoRL 条目（ICRA 为 CCF-B、IROS 为 CCF-C）。

---

7 结论与后续

LRLS-v1.1 把一个探索–开发叙事转成了带固定状态 schema、动作词表、奖励结构、记忆契约、训练顺序、安全规则与指标集的规范，并配上确定性、可拆解的参考仿真。它当前的价值是可证伪的目标与共享的实现契约，而不是一个结果。

按序的后续工作：（1）替换占位符引用并把 related work 对齐 COA、options/HRL、CTDE 与域随机化（本文已部分完成）；（2）构建最小的 Gymnasium 兼容带约束 2D 基准；（3）至少 5 个种子，报告均值

±标准差与消融表，把启发式兜底单独消融，与固定温度 / 熵退火对比学习式调度；（4）此后才准备会议投稿。正确顺序是「规范 → 代码 → 实验 → 选会议」，而非相反。

数据、代码与许可

- 参考仿真：`assets/lrls-sim.html`（单文件离线 HTML，确定性 solver），随本文预印本一并发布。
- 配套心法文本《龙虾之禅 · The Zen of OpenClaw》（41 条，中英）：https://github.com/clawgeek/openclaw-zen
- 功能提案与官方评审回复：https://github.com/openclaw/openclaw/issues/192772
- 本文正文采用 CC BY 4.0；参考实现采用 MIT；AI 生成的吉祥物横图不在上述许可范围内。

附录 **A** — 来源与定位

本预印本整合自 2026 年 11 月 5 日一段十轮对话（原题《龙虾双体智能体强化学习规范》），该对话依次产出古文考据、双体架构、LRLS-v1.0 规范、v1.1 RoboZero 扩展，以及 ICRA / CoRL 两版英文论文草稿。两版草稿含无数据支撑的定性性能断言。本文把这些材料重写为规范，删除不受支持的论断与无效引用，并补上可运行的参考实现，定位为规范的预印本，而非会议论文。

参考文献

[1] Jia, H., Rao, H., Wen, C., & Mirjalili, S. Crayfish Optimization Algorithm. *Artificial Intelligence Review*, 56(Suppl 2), 1919–1979, 2023. doi:10.1007/s10462-023-10520-4

[2] Kaelbling, L. P., Littman, M. L., & Moore, A. W. Reinforcement Learning: A Survey. *JAIR*, 4, 237–285, 1996.

[3] Sutton, R. S., Precup, D., & Singh, S. Between MDPs and Semi-MDPs. *Artificial Intelligence*, 112(1–2), 181–211, 1999.

[4] Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. Soft Actor-Critic. *ICML*, 2018.

[5] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.

[6] Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments. *NeurIPS*, 2017.

[7] Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A., & Wu, Y. The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games. *NeurIPS*, 2022.

[8] Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. Domain Randomization for Sim-to-Real Transfer. *IROS*, 2017.

[9] Kirk, R., Zhang, A., Grefenstette, E., & Rocktäschel, T. A Survey of Zero-Shot Generalisation in Deep RL. *JAIR*, 76, 201–264, 2023.

[10] 荀子《劝学》，约公元前 3 世纪。仅作为命名隐喻的文学来源引用。

[11] 桑杰逊.《龙虾之禅（又名虾之经）· The Zen of OpenClaw》. https://github.com/clawgeek/openclaw-zen, 2026.

[12] 桑杰逊.《龙虾双体强化学习交互式参考仿真》. 单文件 HTML，随本文发布, 2026.